

Université Cadi Ayyad

Faculté des Sciences Semlalia

Projet Machine Learning

Classification du revenu annuel
avec le dataset Adult Income

Réalisé par :

ZAHID Zainab

Encadré par :

Fahd Kalloubi

Table des matières

1	Introduction	2
2	Description du Dataset	2
2.1	Dimensions du dataset	2
2.2	Variables utilisées	2
3	Exploration des données	2
3.1	Distribution des revenus	2
3.2	Corrélations	3
3.3	Analyse des distributions	3
4	Prétraitement des données	3
5	Modèles supervisés utilisés	3
6	Résultats de classification	4
6.1	Accuracy des modèles	4
6.2	Comparaison graphique	4
7	Validation croisée	4
8	Matrice de confusion	5
9	Courbe ROC	5
10	Importance des variables	6
11	Conclusion	6

1 Introduction

Le Machine Learning est un domaine de l'intelligence artificielle permettant de construire des modèles capables d'apprendre à partir des données.

Dans ce projet, nous avons utilisé le dataset Adult Income afin de prédire si le revenu annuel d'un individu dépasse 50K dollars.

L'objectif principal est d'appliquer plusieurs techniques de classification supervisée et de comparer leurs performances.

2 Description du Dataset

2.1 Dimensions du dataset

Le dataset Adult Income contient environ 48 000 instances et 14 attributs décrivant les caractéristiques socio-professionnelles des individus.

La variable cible est :

- income : revenu annuel (>50K ou ≤50K)

2.2 Variables utilisées

Les principales variables utilisées sont :

- age
- education
- occupation
- marital_status
- hours_per_week
- sex
- native_country

3 Exploration des données

3.1 Distribution des revenus




FIGURE 1 – Distribution des revenus

On observe un déséquilibre entre les deux classes du dataset. La majorité des individus possèdent un revenu inférieur ou égal à 50K.

3.2 Corrélations




FIGURE 2 – Matrice de corrélation

Certaines variables présentent une corrélation plus importante avec le revenu, notamment l'âge, le niveau d'éducation et le nombre d'heures travaillées.

3.3 Analyse des distributions




FIGURE 3 – Distribution de l'âge

L'analyse des distributions permet de mieux comprendre la répartition des variables utilisées dans le modèle.

4 Prétraitement des données

Les étapes de prétraitement suivantes ont été appliquées :

- Remplacement des valeurs manquantes
- Suppression des valeurs nulles
- Suppression des doublons
- Encodage des variables catégorielles
- Normalisation des données
- Séparation des données en ensembles Train/Test

Ces étapes permettent d'améliorer la qualité des données avant l'entraînement des modèles de Machine Learning.

5 Modèles supervisés utilisés

Les modèles de classification suivants ont été utilisés :

- K-Nearest Neighbors (KNN)

- Decision Tree
- Logistic Regression
- Random Forest

Chaque modèle possède des caractéristiques différentes permettant de comparer leurs performances sur le dataset.

6 Résultats de classification

6.1 Accuracy des modèles

Modèle	Accuracy
KNN	0.84
Decision Tree	0.81
Logistic Regression	0.85
Random Forest	0.87

Le modèle Random Forest obtient les meilleures performances grâce à sa capacité à combiner plusieurs arbres de décision.

6.2 Comparaison graphique




FIGURE 4 – Comparaison des modèles

7 Validation croisée

La validation croisée permet d'évaluer la stabilité des performances du modèle sur plusieurs divisions des données.

Les résultats obtenus montrent que le modèle Random Forest possède de bonnes performances générales.

8 Matrice de confusion




FIGURE 5 – Matrice de confusion du modèle Random Forest

La matrice de confusion montre que le modèle classe correctement la majorité des individus. Cependant, certaines erreurs de classification restent présentes.

9 Courbe ROC




FIGURE 6 – Courbe ROC du modèle Random Forest

La courbe ROC montre une bonne capacité de discrimination du modèle. La valeur élevée de l'AUC indique une bonne qualité de classification.

10 Importance des variables




FIGURE 7 – Importance des variables

Les variables liées à l'éducation, à l'âge et au temps de travail apparaissent comme les plus importantes dans la prédiction du revenu annuel.

11 Conclusion

Dans ce projet, plusieurs techniques de Machine Learning supervisé ont été appliquées sur le dataset Adult Income.

Après le prétraitement des données, plusieurs modèles ont été entraînés et évalués :

- KNN
- Decision Tree
- Logistic Regression
- Random Forest

Les résultats montrent que le modèle Random Forest offre les meilleures performances.

Ce projet nous a permis d'appliquer les principales étapes d'un pipeline de Machine Learning :

- exploration des données
- prétraitement
- entraînement des modèles
- évaluation des performances